

TERAPIA
IA RESPONSÁVEL

Governança de Inteligência Artificial e Caso de Segurança

Finalidade de uso, riscos, controles, evidências e risco residual

Projeto	TerapIA: Plataforma Móvel para apoio mental com Inteligência Artificial
Coordenador	Carlos Gracioli Neto
Instituição	Instituto Federal de Educação, Ciência e Tecnologia de Mato Grosso - IFMT - Campus Várzea Grande
Período	01/09/2025 a 31/08/2026
Referência	Projeto de Pesquisa 138/2025 - PROPES/IFMT

Repositório técnico e documentação: <https://github.com/devfullstackNeto/terapia>

Entrega final - 2026

1. Finalidade de uso

O componente conversacional destina-se a psicoeducação, apoio emocional de baixo limiar, navegação pelos recursos da plataforma e incentivo ao contato humano quando apropriado. Não se destina a diagnóstico, tratamento autônomo, avaliação psicológica formal, prescrição ou gerenciamento de crise sem rede humana.

2. Usos proibidos

- Diagnosticar transtornos ou confirmar autodiagnóstico.
- Recomendar medicamento, dose, suspensão ou troca de tratamento.
- Realizar avaliação psicológica formal.
- Assumir identidade profissional ou vínculo terapêutico.
- Reforçar segredo, exclusividade ou substituição da rede humana.
- Usar diário privado como contexto generativo por padrão.
- Produzir escore clínico individual a partir de telemetria.

3. Princípios de governança

Princípio	Implementação
Autonomia	IA identificada; opções humanas visíveis; consentimentos claros
Benefício e segurança	Gateway de segurança, conjunto dourado e fluxo de incidentes
Transparência	Fontes, versão da base e provedor/modelo registrados
Responsabilização	Responsáveis técnicos, de conteúdo e de segurança
Equidade	Testes por linguagem, faixa etária e personas; revisão de vieses
Privacidade	Minimização e separação de conteúdo íntimo
Gestão de mudanças	Versões de modelo, instruções, base e políticas com regressão

4. Caso de segurança

Claim	Argumento	Evidência
SC-01: sem autonomia clínica	Fluxos clínicos não existem no domínio da IA	Testes de diagnóstico/prescrição + arquitetura
SC-02: conteúdo fundamentado	Geração depende de base aprovada	Testes de recuperação + cobertura de fontes
SC-03: segurança independente	Políticas críticas antecedem o provedor	Testes unitários + conjunto dourado
SC-04: dependência não reforçada	Política específica detecta exclusividade	Casos de antidependência
SC-05: conteúdo íntimo isolado	Diário e mensagens segregados das análises	Testes de RBAC e linhagem de dados
SC-06: troca de modelo controlada	Mudança exige regressão de segurança	Relatório de QA e registro de configuração

5. Registro de perigos

Perigo	Severidade	Controle	Risco residual
Diagnóstico indevido	Alta	Política + recusa + testes	Baixo-médio
Prescrição/medicação	Alta	Recusa rígida + profissional humano	Baixo
Falha em cenário crítico	Crítica	Fluxo dedicado + contingência	Médio até validação de campo
Dependência emocional	Alta	Política e UX de antidependência	Baixo-médio
Exposição de diário	Crítica	Segregação + RBAC + registros minimizados	Baixo
Contato inventado	Alta	Diretório configurado; números não inventados	Baixo

6. Pipeline e provedores

Pipeline obrigatório do assistente



Controles antes e depois do provedor

A abstração contempla provedor simulado, provedor compatível com API OpenAI e integração Ollama. Na validação final, o host de QA não disponibilizou o serviço Ollama/Mistral para inferência; a verificação de disponibilidade identificou essa condição e a contingência para o modo simulado operou sem afetar as políticas, a recuperação de fontes ou os fluxos obrigatórios.